

Tối ưu hóa hàm mất mát Ridge

cho bài toán định giá điện thoại đã qua sử dụng

Nguyễn Hồng Phúc (25007860)
Phạm Huy Hoàng (25007878)
Bùi Quang Huy (25007877)

Trường Đại học Khoa học Tự nhiên - ĐHQGHN
Khoa Toán - Cơ - Tin học
Môn: Tối ưu hóa nâng cao

Ngày 10 tháng 8 năm 2026

Đặt vấn đề

Khảo sát tham số

So sánh tổng hợp

So sánh với thư viện

Kết luận



- ▶ Dữ liệu định giá điện thoại đã qua sử dụng (Kaggle): 1 000 000 bản ghi, 28 cột, không giá trị thiếu và không bản ghi trùng lặp, nên phần chuẩn bị chỉ còn mã hóa và chuẩn hóa.
- ▶ Thí nghiệm chạy trên mẫu 200 000 bản ghi, $n = 160\,000$ điểm huấn luyện, vì một lần tính gradient trên toàn bộ dữ liệu mất 271 ms thay vì 39 ms.
- ▶ $d = 280$ sau mã hóa, gồm 21 cột định lượng gốc, 210 tích từng cặp, 14 bình phương và 35 cột one-hot: biến tương tác sinh ra phần lớn kích thước bài toán.
- ▶ Biến mục tiêu lấy logarit vì giá bán lại lệch phải rõ rệt, trung vị 18 555 so với trung bình 22 598.
- ▶ Trọng tâm của bài tập là phần tối ưu hóa chứ không phải phần mô hình hóa.



Hàm mục tiêu và các hằng số quyết định tốc độ hội tụ

$$\min_{w \in \mathbb{R}^d} f(w) = \frac{1}{2n} \|Xw - y\|_2^2 + \frac{\lambda}{2} \|w\|_2^2, \quad L = \lambda_{\max}\left(\frac{1}{n} X^\top X\right) + \lambda, \quad \mu = \lambda_{\min}\left(\frac{1}{n} X^\top X\right) + \lambda, \quad \kappa = L/\mu$$


L	2,683
μ	0,01
κ	268,3
λ	0,01
f^*	0,023 743 0

Hessian $\frac{1}{n} X^\top X + \lambda I$ không phụ thuộc w , nên bài toán lồi mạnh và có nghiệm đóng w^* . Nhờ vậy f^* tính được trước khi chạy thuật toán nào, và mọi biểu đồ vẽ được sai số tuyệt đối $f(w_k) - f^*$ trên thang logarit.

Mã trận Gram có hạng 273 trên 280 và trị riêng kế tiếp chỉ cỡ $2 \cdot 10^{-8}$, tức phần đóng góp của dữ liệu vào μ coi như bằng không, nên $\mu = \lambda$ và $\kappa = L/\lambda$: hệ số hiệu chỉnh là đại lượng duy nhất quyết định số điều kiện.



Gradient descent: độ dài bước cố định



Chênh 10% quanh ngưỡng $2/L = 0,745$ đã đổi hẳn kết cục: $t = 2.1/L$ đẩy hàm mục tiêu lên $5,4 \times 10^{11}$, còn $t = 1.9/L$ hội tụ sau 20 vòng lặp.



Gradient descent: backtracking và cách chọn độ dài bước


$\alpha = 0.5$	Đánh giá hàm / vòng lặp	Vòng lặp đạt 10^{-6}	Thời gian (s)
$\beta = 0.5$	1,39	15	0,852
$\beta = 0.8$	2,37	20	1,617
$\beta = 0.9$	3,96	20	1,799

- ▶ β quyết định chi phí, còn α gần như không ảnh hưởng, vì ba giá trị $\alpha \in \{0.1, 0.3, 0.5\}$ chỉ chênh nhau 4,8% về số lần đánh giá hàm.
- ▶ Trong vùng ổn định, số vòng lặp tỉ lệ nghịch với độ dài bước, 20, 40, 80 vòng ứng với $t = 1.9/L$, $1/L$, $0.5/L$, nên chọn t càng gần $2/L$ càng tốt.
- ▶ Backtracking chậm hơn bước cố định tốt nhất 10% (0,852s so với 0,773s), và khoản chênh đó mua lấy chỗ không phải biết L .




SGD: độ dài bước theo kích thước lô

$$L = 2,683, \quad L_{\max} = \max_i \|x_i\|^2 + \lambda = 3109,7 \quad \Rightarrow \quad L_B = L + \frac{L_{\max} - L}{B}, \quad \eta_0 = 1/L_B$$



Dùng chung $\eta = 0.1/L$ thì lô kích thước 1 phân kỳ thành NaN ngay trong lượt duyệt (epoch) đầu tiên, còn lô 1024 đạt sai số $1,1 \times 10^{-4}$. Ngưỡng ổn định của một bước ngẫu nhiên phụ thuộc độ cong của các mẫu trong lô chứ không phụ thuộc L , mà hai hằng số này chênh nhau 1159 lần, nên chỉ lô lớn mới nằm trong vùng ổn định của một bước tính theo L .

SGD: quy tắc chọn độ dài bước




Quy tắc	Sai số cuối
hằng	$9,58 \times 10^{-4}$
$\eta_0/\sqrt{k+1}$	$1,46 \times 10^{-4}$
$\eta_0/(1 + 0.5k)$	$2,90 \times 10^{-5}$
bậc thang	$5,80 \times 10^{-6}$

Bước hằng dừng ở một lân cận của w^* bán kính cỡ $\mathcal{O}(\eta\sigma^2/\mu)$, nên muốn sai số giảm tiếp thì phải hạ dần η_k để bán kính co theo.



Accelerated gradient descent




Khởi động lại không đổi số vòng lặp đạt 10^{-6} , nhưng giảm tổng thời gian từ 10,5 s xuống 4,86 s vì nó khử dao động ở phần đuôi.

- ▶ Với $\alpha = 0.3$ và $t_0 = 1$, phương pháp không hội tụ mà dừng ở $5,5 \times 10^{-5}$, vì line search chạy tại điểm ngoại suy y_k nên chỉ bảo đảm $f(w_{k+1}) < f(y_k)$ và Armijo chấp nhận t tới $1/\mu = 100$ trong khi ngưỡng ổn định là $2/L = 0,745$.
- ▶ Hai cách xử lý đều đưa phương pháp về hội tụ, lấy $\alpha = 0.5$ để điều kiện Armijo trùng bỏ đề giảm, hoặc khởi tạo $t_0 = 1/L$ để line search chỉ thu nhỏ từ một giá trị vốn an toàn. Momentum phải tính theo bước thực tế, $\beta = (1 - \sqrt{t\mu}) / (1 + \sqrt{t\mu})$.

Phương pháp Newton


$$w_1 = w_0 - (\nabla^2 f)^{-1} \nabla f(w_0) = w^*$$

Với hàm bậc hai, một vòng lặp là đủ và bước Newton chính là nghiệm đúng, nên toàn bộ lời giải mất 0,076 s. Đại lượng đáng so ở đây vì thế là chi phí một vòng lặp, $\mathcal{O}(nd^2 + d^3)$ so với $\mathcal{O}(nd)$ của gradient descent, chứ không phải số vòng lặp.




So sánh theo số vòng lặp

All methods at their best setup



All methods at their best setup



Bảng tổng hợp

Thuật toán	Cấu hình tốt nhất	Vòng lặp	Thời gian (s)	Tổng (s)
Newton	$t = 1$, Cholesky	1	0,076	0,076
L-BFGS	$m = 3$	8	0,448	3,18
GD	$t = 2/(L + \mu)$	20	0,773	44,32
GD	backtracking $\alpha = \beta = 0.5$	15	0,852	29,28
AGD	β_k tăng dần, khởi động lại	20	0,879	4,86
SGD	$B = 64$, giảm bậc thang	–	–	2,45

- ▶ Cột *Vòng lặp* và *Thời gian* đo tới ngưỡng 10^{-6} , cột *Tổng* đo tới giới hạn số học.
- ▶ Ở 10^{-6} , ba phương pháp bậc một chênh nhau dưới 14% vì giai đoạn đầu do các hướng có độ cong lớn chi phối; ở độ chính xác cao, nơi μ mới chi phối, AGD nhanh hơn GD 9 lần.
- ▶ L-BFGS là một trong ba thuật toán cài đặt thêm ngoài bốn thuật toán bắt buộc, trình bày ở phụ lục.



Bộ ước lượng	sai số $f - f^*$	thời gian (s)	RMSE test
Ridge(solver='cholesky')	0	0,112	0,206 01
Ridge(solver='lsqr')	$2,35 \times 10^{-9}$	0,621	0,206 01
Ridge(solver='sag')	$1,46 \times 10^{-8}$	3,955	0,206 01
SGDRegressor (mặc định)	$1,16 \times 10^{-3}$	1,018	0,212 02
LinearRegression	$3,48 \times 10^{-5}$	1,116	0,205 79

- ▶ Nhóm quy hàm mục tiêu của thư viện về cùng một dạng trước khi so sánh, $\alpha = \lambda n$ cho Ridge và $\alpha = \lambda$ cho SGDRegressor, và kiểm chứng cả hai phép quy đổi bằng số.
- ▶ Solver trực tiếp giải thẳng chính hệ mà một bước Newton giải, nên với bài toán có nghiệm đóng và d vài trăm thì khó có phương pháp lặp nào sánh được.
- ▶ SGDRegressor mặc định dừng cách f^* một khoảng $1,16 \times 10^{-3}$, gấp 200 lần cấu hình SGD tự cài đặt, vì quy tắc chọn bước mặc định không tính theo L_B của bài toán.



- ▶ **Độ dài bước:** $2/L$ là ranh giới thật, chênh 10% đủ để đổi giữa hội tụ và phân kỳ, nên trong vùng ổn định cứ chọn càng gần $2/L$ càng tốt.
- ▶ **Backtracking:** β quyết định chi phí còn α gần như không; ghép với phương pháp tăng tốc thì phải lấy $\alpha = 1/2$ hoặc $t_0 = 1/L$, và momentum phải tính theo bước thực tế.
- ▶ **SGD:** độ dài bước phải theo kích thước lô, vì $L_{\max}/L = 1159$ trên bộ dữ liệu này.
- ▶ **Bậc hai:** Newton chính là nghiệm đóng nên nhanh hơn hẳn, nhưng kết luận đó gắn với dạng bậc hai và không chuyển sang bài toán phi tuyến.
- ▶ **Lý thuyết và thực nghiệm:** cận chặt ở phần đuôi và lỏng ở giai đoạn đầu, vì phổ trị riêng của bài toán tập trung chứ không trải đều.



- ▶ Chọn λ trên một đường cong CV phẳng.
- ▶ Chuẩn hóa dữ liệu, cách tạo biến tương tác và số điều kiện.
- ▶ SGD: ảnh hưởng của kích thước lô khi mỗi lô có bước riêng.
- ▶ Đối chiếu với tốc độ lý thuyết.
- ▶ Quy đổi hàm mục tiêu của thư viện, và so sánh theo thời gian.
- ▶ Ảnh hưởng của λ tới số điều kiện và tới RMSE.
- ▶ Ba thuật toán cài đặt thêm.
- ▶ Kiểm thử tính đúng đắn của cài đặt.




Chọn λ trên một đường cong CV phẳng

- ▶ Đường cong CV 5 fold cho sai số giống nhau tới bốn chữ số thập phân với mọi λ từ 10^{-6} đến 10^{-3} , vì mức hiệu chỉnh nhỏ hơn nhiều của dữ liệu thì không đổi được sai số dự báo.
- ▶ Cùng khoảng đó, $\kappa = L/\lambda$ chênh nhau 1000 lần, nên λ vẫn phải chọn cẩn thận bằng một tiêu chí ngoài cross-validation.
- ▶ Trên đường cong phẳng, điểm cực tiểu chỉ phản ánh nhiều của phép chia fold, nên nhóm dùng quy tắc một sai số chuẩn: chọn λ lớn nhất còn nằm trong một sai số chuẩn của giá trị tốt nhất.
- ▶ Kết quả $\lambda = 0,01$, $\kappa = 268,3$, đôi lấy RMSE test 0,206 01 so với 0,205 79, kém 0,1%.



Chuẩn hóa dữ liệu và số điều kiện



$\kappa = 268,3$ sau khi chuẩn hóa so với $\kappa = 46\,540$ khi giữ thang đo không đồng nhất, và hệ số co rút $1 - \mathcal{O}(1/\kappa)$ nhỏ đi đúng theo tỉ lệ 173 lần ấy.



Ảnh hưởng của cách tạo biến tương tác tới κ


Tích của hai cột định lượng có thể lấy trên thang gốc hoặc trên cột đã chuẩn hóa.

	thang gốc	cột đã chuẩn hóa
L	17,14	2,68
số trị riêng $< 10^{-6}$	48	7

Không gian cột sinh ra vẫn như cũ, chỉ cách biểu diễn thay đổi, nhưng một cột tích trên thang gốc có phương sai lớn hơn các cột còn lại nhiều bậc và kéo riêng trị riêng lớn nhất lên, nên số điều kiện chênh nhau 6,4 lần.



SGD: ảnh hưởng của kích thước lô



Khi mỗi lô có bước riêng, cả năm cấu hình về cùng mức 10^{-3} sau 30 lượt duyệt, nhưng thời gian chênh 14 lần, 27,4s với $B = 1$ so với 1,9s với $B = 1024$. Chênh lệch nằm ở chi phí cố định của mỗi lần cập nhật trong Python chứ không ở số phép tính, do $B = 1$ thực hiện 160 000 lần cập nhật mỗi lượt duyệt.



	Quan sát	Cận lý thuyết
GD, $t = 2/(L + \mu)$	0,985 20	0,985 20
AGD, β_k tăng dần + restart	0,654 56	0,938 95

- ▶ Cận của GD chặt tới năm chữ số thập phân ở phần đuôi, vì ở đó đúng thành phần ứng với trị riêng nhỏ nhất chi phối sai số.
- ▶ Nhưng nó nói rất ít về giai đoạn đầu, khi GD đạt 10^{-6} sau 20 vòng lặp còn ước lượng lý thuyết là $\frac{1}{2}\kappa \ln(10^6) \approx 1850$.
- ▶ Phổ trị riêng của bài toán tập trung chứ không trải đều giữa μ và L như trường hợp xấu nhất mà cận nhắm tới, và cùng lý do đó khiến momentum tăng dần thắng momentum hằng.

- ▶ Ridge cực tiểu hóa $\|Xw - y\|_2^2 + \alpha \|w\|_2^2$, nên $\alpha = \lambda n$.
- ▶ SGDRegressor cực tiểu hóa đúng dạng (1), nên $\alpha = \lambda$.

$$f(w) = \frac{1}{2n} \|Xw - y\|_2^2 + \frac{\lambda}{2} \|w\|_2^2 \quad (1)$$

Nhóm kiểm chứng cả hai phép quy đổi bằng số chứ không bằng suy luận trên giấy: nghiệm Ridge cách nghiệm đóng $1,06 \times 10^{-14}$, và chênh lệch hàm mục tiêu bằng đúng 0 trong số học dấu phẩy động.



Kết quả so với thư viện, theo thời gian



λ	κ	Vòng lặp đạt 10^{-6}	Thời gian (s)	RMSE test
0,001	2674	40	1,756	0,205 80
0,01	268,3	40	1,771	0,206 01
0,1	27,73	30	1,233	0,219 16

- ▶ Vì $\mu = \lambda$, tăng λ mười lần thì giảm κ đúng mười lần.
- ▶ Nhưng κ giảm 96 lần chỉ đổi được số vòng lặp từ 40 xuống 30, trong khi RMSE xấu đi 6,5%, vì giai đoạn đầu do các hướng có độ cong lớn chi phối chứ không do κ .
- ▶ Hiệu chỉnh vì thế có hai vai trò không cùng chiều, thống kê và tối ưu hóa, và đánh đổi giữa chúng chỉ có lợi khi cần độ chính xác cao.



- ▶ **Heavy ball.** Cùng dạng momentum như Nesterov nhưng ngoại suy sau khi lấy gradient:
 $w_{k+1} = w_k - t \nabla f(w_k) + \beta(w_k - w_{k-1})$, với $t = 4/(\sqrt{L} + \sqrt{\mu})^2$ và $\beta = ((\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1))^2$.
- ▶ **Newton-CG.** Giải hệ Newton bằng gradient liên hợp. Mỗi bước CG chỉ cần một tích Hessian nhân vector, $\frac{1}{n} X^\top (Xv) + \lambda v$, chi phí $\mathcal{O}(nd)$, nên không phải lập ma trận $d \times d$. Ở đây chậm hơn Newton 25 lần vì $d = 280$ còn nhỏ.
- ▶ **L-BFGS.** Xấp xỉ nghịch đảo Hessian từ m cặp (s_k, y_k) gần nhất qua đệ quy hai vòng, chi phí $\mathcal{O}(md)$ mỗi vòng lặp. Nằm giữa nhóm bậc một và bậc hai về cả chi phí lẫn tốc độ, đạt 10^{-6} sau 8 vòng lặp và 0,448 s.

Adam cũng được cài đặt nhưng không đưa vào so sánh chính, vì trên hàm bậc hai lỗi mạnh có nghiệm đóng, cơ chế chia theo căn bậc hai của moment bậc hai không mang lại lợi thế nào.



46 phép thử tự động chạy trước khi khảo sát tham số. Bốn phép thử đối chiếu trực tiếp với công thức giải tích:

- ▶ gradient giải tích so với sai phân trung tâm tại $\varepsilon = 10^{-6}$, sai số tương đối dưới 10^{-6} ;
- ▶ Hessian so với sai phân của gradient, cùng ngưỡng;
- ▶ nghiệm đóng là điểm dừng, $\|\nabla f(w^*)\| < 10^{-12}$;
- ▶ mười câu hình thuật toán cùng hội tụ về một nghiệm trên bài toán tổng hợp $n = 100$, $d = 5$.

Ba phép thử về mặt phương pháp luận: gradient descent phải phân kỳ khi $t > 2/L$; SGD với bước hằng phải dừng cách f^* một khoảng dương; ghi lịch sử dày hay thưa phải cho cùng số lần đánh giá hàm mục tiêu.

